

Detecção de linhas de plantio em plantações de cana-de-açúcar utilizando *deep learning*

João Batista Ribeiro
joao.b@ufu.br

Orientador: Prof. Dr. André Ricardo Backes
Coorientador: Prof. Dr. Mauricio Cunha Escarpinati

Banca

Prof. Dr. Henrique Coelho Fernandes (UFU)
Prof. Dr. João Fernando Mari (UFV)
Prof. Dr. Thiago Pirola Ribeiro (UFU)

Roteiro



- Introdução
- Objetivos
- Fundamentação Teórica
- Metodologia
- Experimentos e Resultados
- Conclusão

Introdução

Introdução

O **crescimento populacional** tem impulsionado a demanda por alimentos e a utilização inteligente e sustentável dos **recursos naturais**

Agricultura de Precisão (AP) busca suprir essa demanda utilizando os recursos sob medida com base nas informações coletadas

- Muitos dos avanços na AP são fortemente dependentes das tecnologias de **Processamento Digital de Imagens** (PDI)
- As imagens utilizadas têm variadas fontes (e.g., câmeras acopladas em **Veículos Aéreos Não Tripulados** (VANTs) e de satélites) dependendo da aplicação

Cana-de-açúcar

Um dos cenários de grande utilização da AP no Brasil é no cultivo de **cana-de-açúcar**, com **10 milhões de hectares** de área plantada (**maior produtor mundial**)



Figura: Exemplos de imagens plantações de cana-de-açúcar capturadas por VANTs (SILVA, 2020)

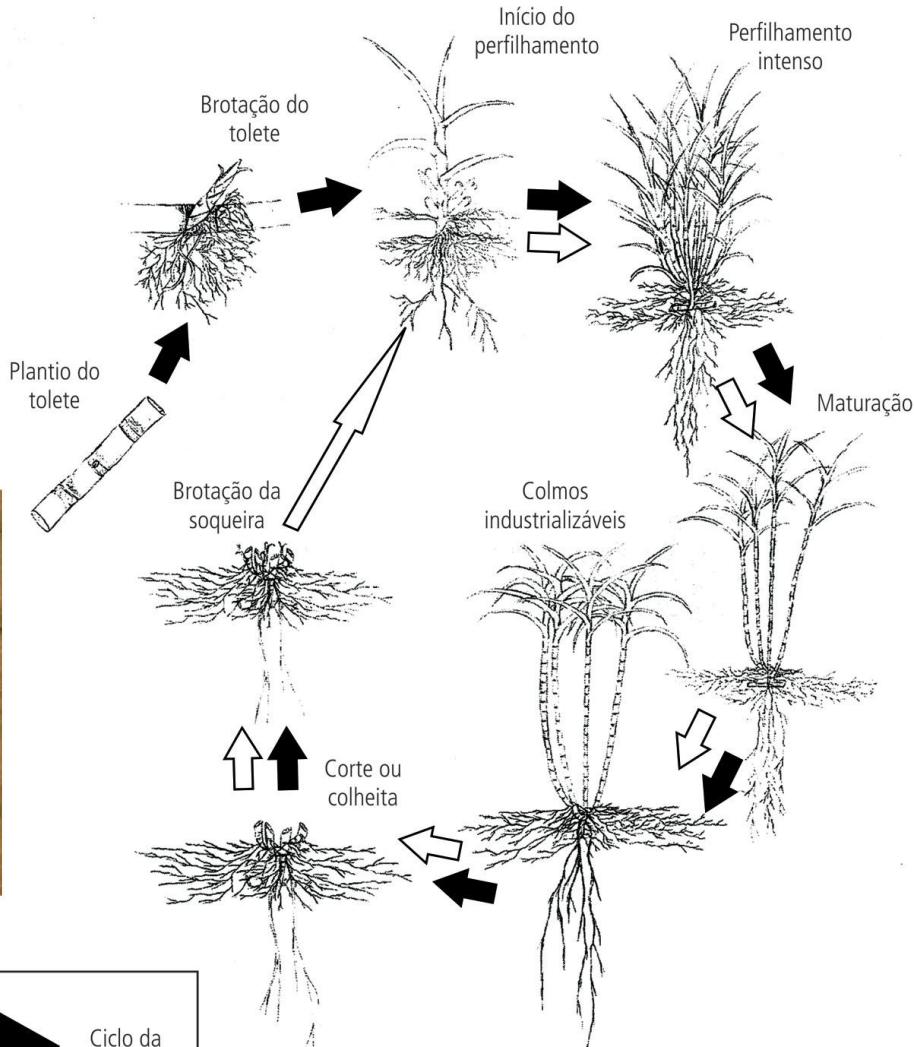
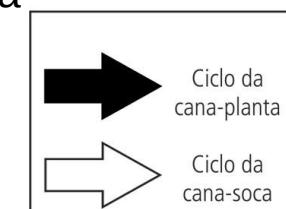


Figura: Ciclos de desenvolvimento da cana-de-açúcar (SEGATO et al., 2006)

Motivação

Detecção de linhas de plantio

- É uma **etapa importante** para outras **aplicações da AP** (e.g., detecção de ervas daninhas, mapeamento e previsão de produção de safra, detecção de falhas no plantio)
- Além de ser utilizada pelos **veículos autônomos**, para se **guiarem** na plantação, o que pode evitar o **pisoteamento da cultura**

É uma **tarefa complexa** e com vários desafios que podem **atrapalhar o seu processo de detecção** (e.g., presença de ervas daninhas com cor semelhante às da cultura, solo de variadas tonalidades, variações nas condições de iluminação)

Objetivos

- Estudar e analisar os diferentes **métodos de segmentação** automática em **imagens de VANTs** com foco em imagens de plantações de **cana-de-açúcar** e propor melhorias na **deteção das linhas de plantio**

Objetivos específicos:

- Detectar as linhas de plantio nas imagens das plantações de cana-de-açúcar, com plantas em **variados estágios** (antes do primeiro corte (cana-planta) e depois do primeiro corte (cana-soca)).
- Desenvolver um método capaz de identificar, nas imagens obtidas por VANTs, as linhas de plantio com **formatos** de linhas retas e linhas curvas.

Fundamentação Teórica

Segmentação de Imagens

- Tem como objetivo **dividir a imagem** em regiões ou objetos de interesse
 - O nível de divisões depende do problema a ser resolvido
 - Ao fim da etapa, a imagem é dividida em várias regiões e sem sobreposição entre elas
- Quando é necessário rotular cada pixel da imagem a uma determinada classe (**segmentação semântica**)

Operações Morfológicas

- Foco na forma e a **estrutura dos objetos** em uma imagem
- Geralmente com **imagens binárias** e com **baixo custo computacional**

Exemplos

- Erosão: **remove** pixels da borda dos objetos
- Dilatação: **adiciona** pixels da borda dos objetos
- Abertura (Erosão + Dilatação): tende a **quebrar trechos estreitos**
- Fechamento (Dilatação + Erosão): tende a **fechar pequenas lacunas**

Índices de Vegetação (IV)

IV são **combinações algébricas** de bandas espectrais, de modo a **destacar a vegetação e suas propriedades** (e.g., quantidade de biomassa, deficiências hídricas)

Tabela: Índices de Vegetação. Adaptado de LU et al., 2019

IV	Nome	Equação
VARI	<i>Visible Atmospherically Resistant Index</i>	$\text{VARI} = \frac{g - r}{g + r - b}$
ExG	<i>Excess Green Index</i>	$\text{ExG} = 2 * g - r - b$
ExR	<i>Excess Red Vegetation Index</i>	$\text{ExR} = \frac{1,4 * R - G}{G + R + B}$
ExB	<i>Excess Blue Vegetation Index</i>	$\text{ExB} = \frac{1,4 * B - G}{G + R + B}$
ExGR	<i>Excess Green minus Excess Red</i>	$\text{ExGR} = \text{ExG} - \text{ExR}$

R , G e B correspondem as bandas RGB de uma imagem
 r , g e b são as coordenadas cromáticas

- Bandas RGB

- Bandas infravermelho e outras

Deep Learning

Subárea do aprendizado de máquina

- Aprendizado **continuado por camadas**

Convolutional Neural Networks (CNNs)

- Estado da arte para vários problemas PDI e Visão Computacional
- Principais camadas
 - Camada **convolucional**
 - Camada de *pooling*
- Exemplos: U-Net, LinkNet, PSPNet

U-Net

- Encoder
- Decoder
- Skip connection

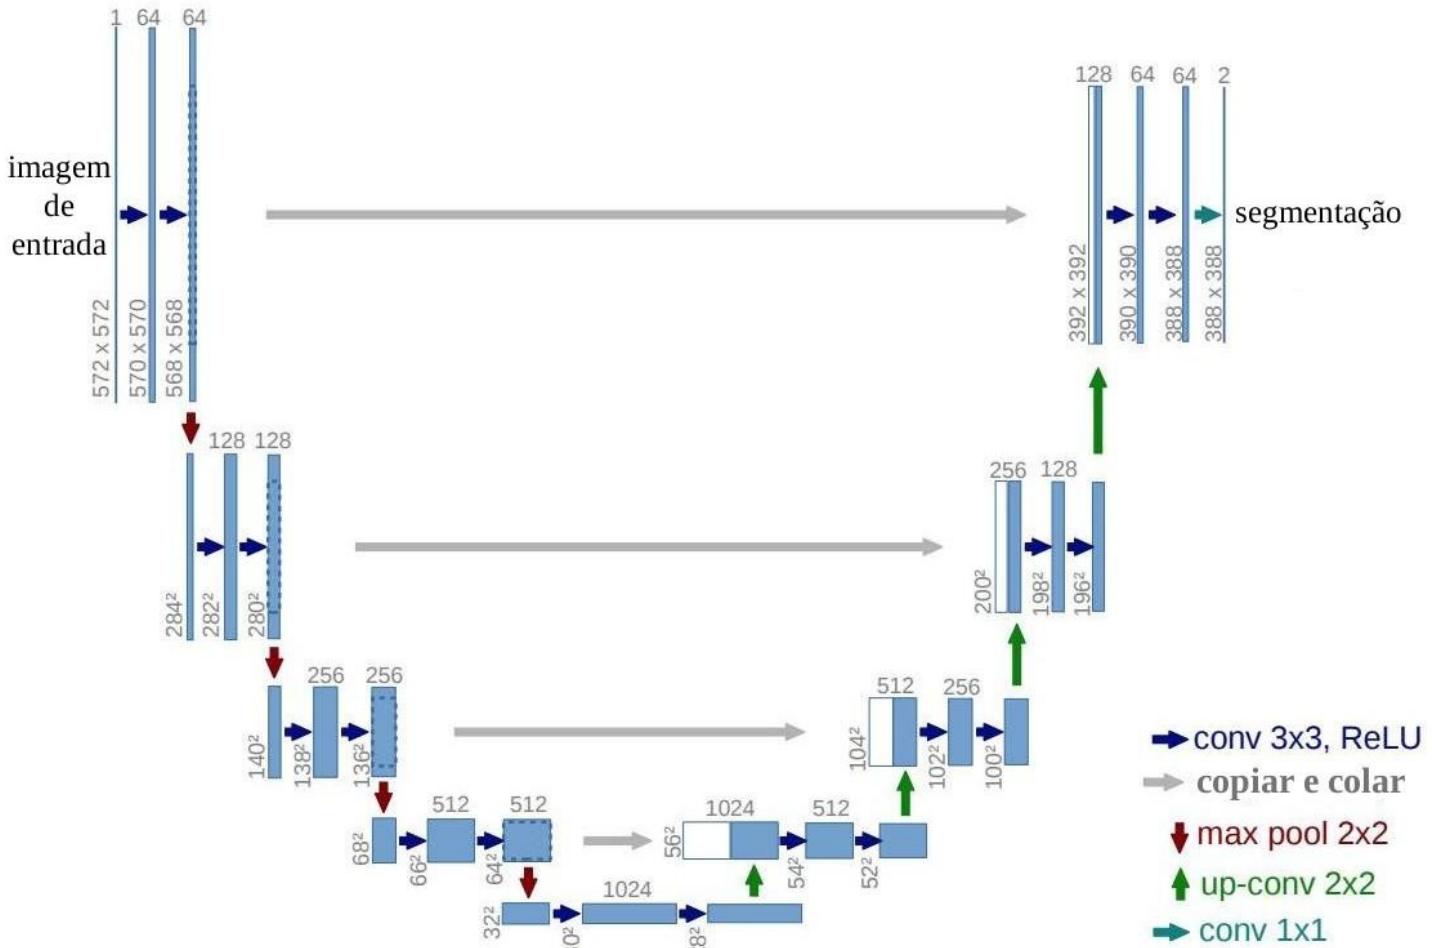


Figura: Arquitetura da U-Net
Adaptado de Ronneberger, Fischer e Brox (2015)

LinkNet

- *Residual blocks*
- Foco na eficiência das conexões

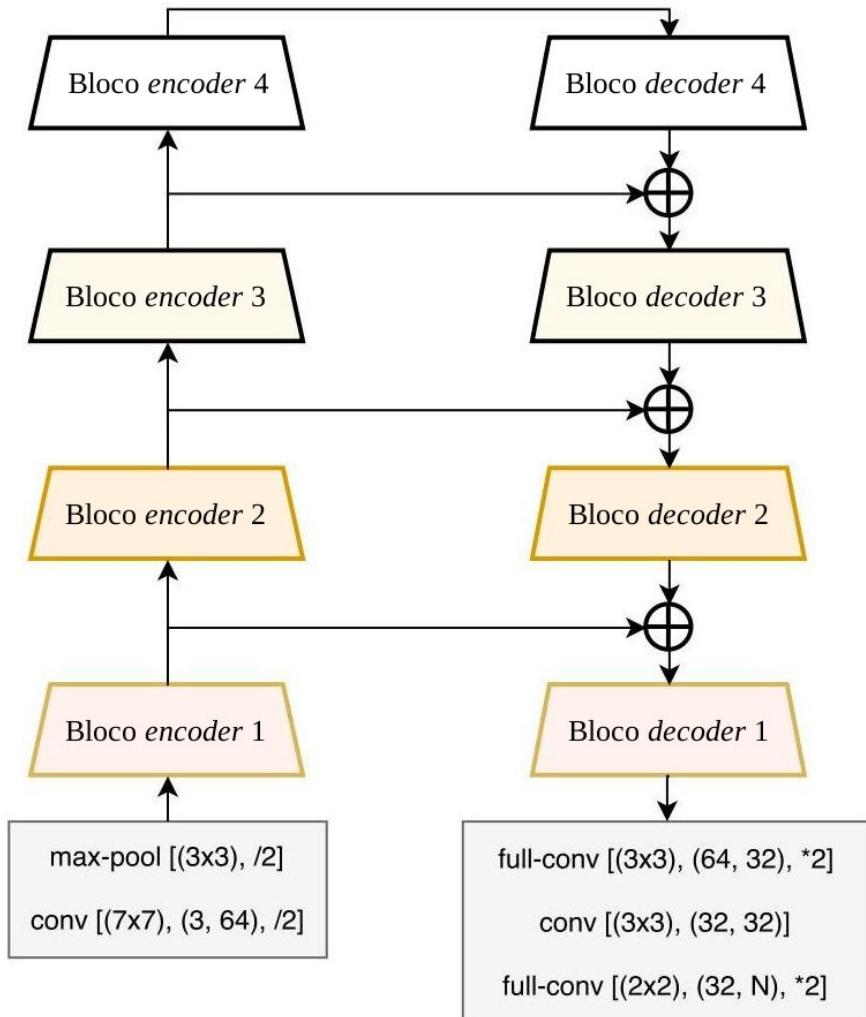


Figura: Arquitetura da LinkNet
Adaptado de Chaurasia e Culurciello (2017)

PSPNet

- Esquema de **agrupamento piramidal**
 - Informações contextuais em várias escalas

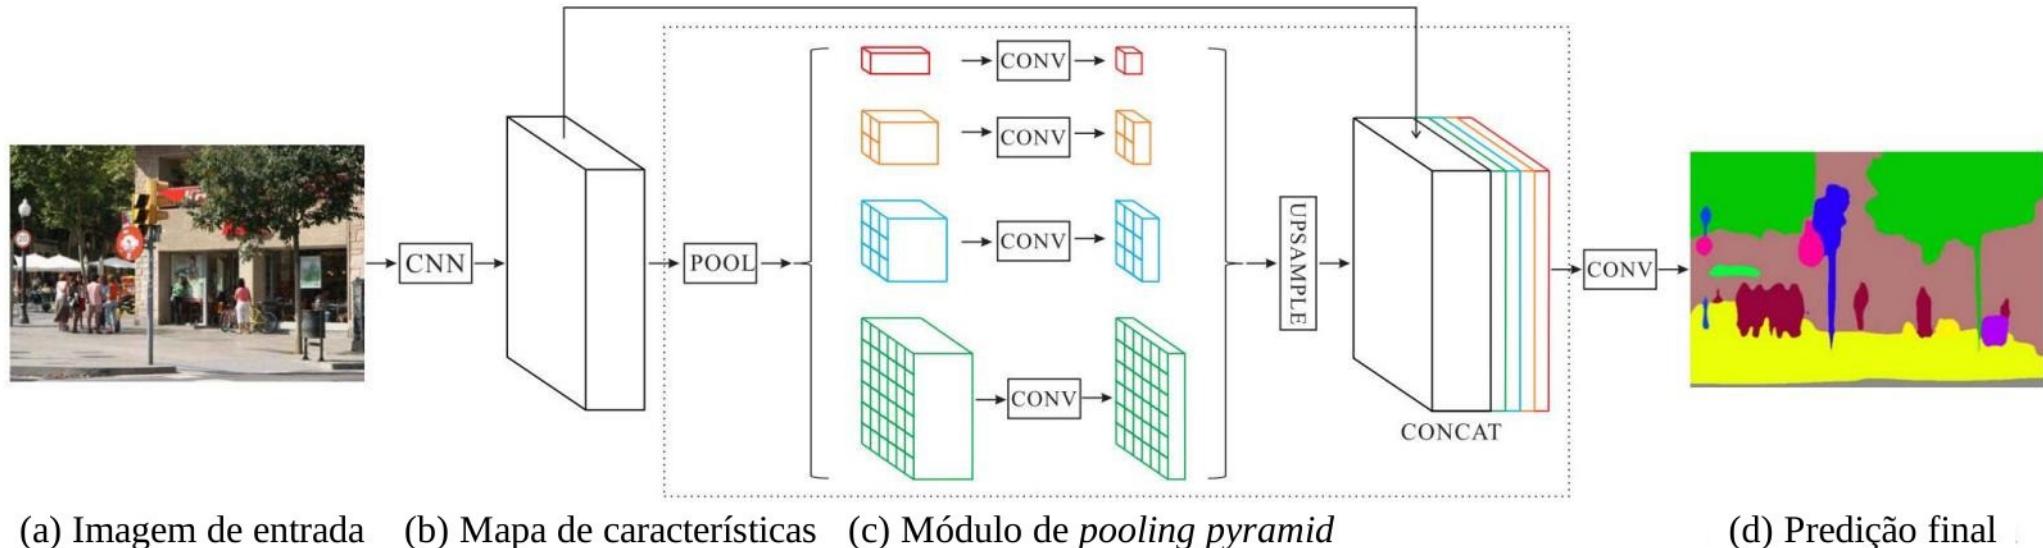


Figura: Arquitetura da PSPNet
Adaptado de Zhao et al. (2017)

Deep Learning

A escolha da CNN depende das necessidades específicas do problema (e.g., do tamanho do conjunto de dados e da complexidade da tarefa)

Transfer learning (transferência do aprendizado)

- Modelo **pré-treinados** (e.g., com o ImageNet)
- *Backbone*: VGG16
- *Fine-tuning (ajuste fino)*
 - partes da rede são “congeladas” e o modelo é **ajustado** para o novo problema

Metodologia

Metodologia

- Aquisição das Imagens
 - *Datasets* - VANTs
- Segmentação
 - CNNs
- Avaliação dos Resultados
 - Coeficiente de Dice
- Pós-processamento
 - Operações Morfológicas

Datasets

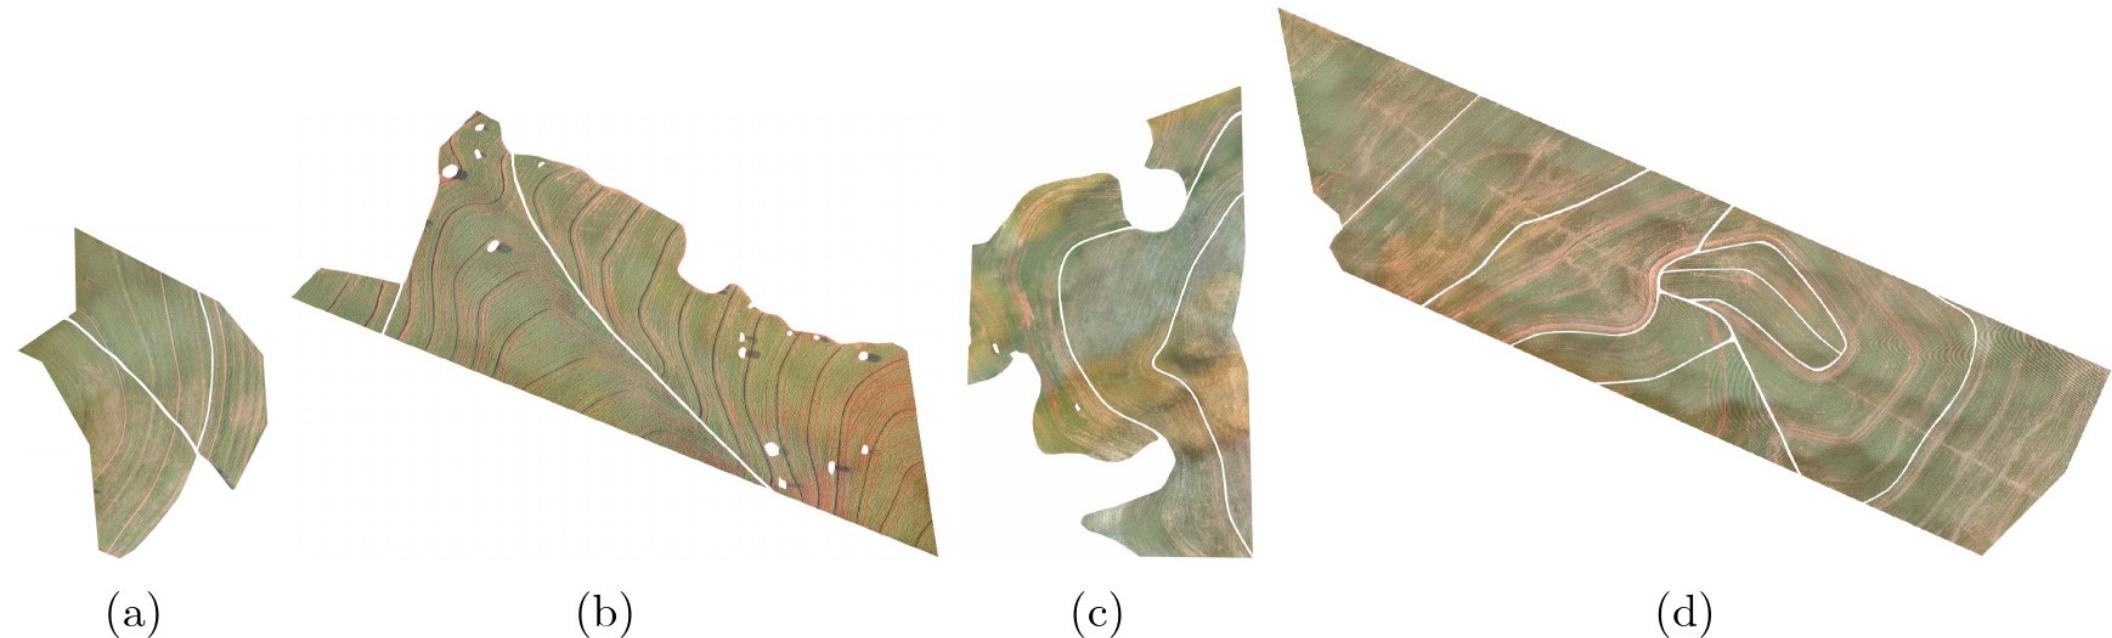
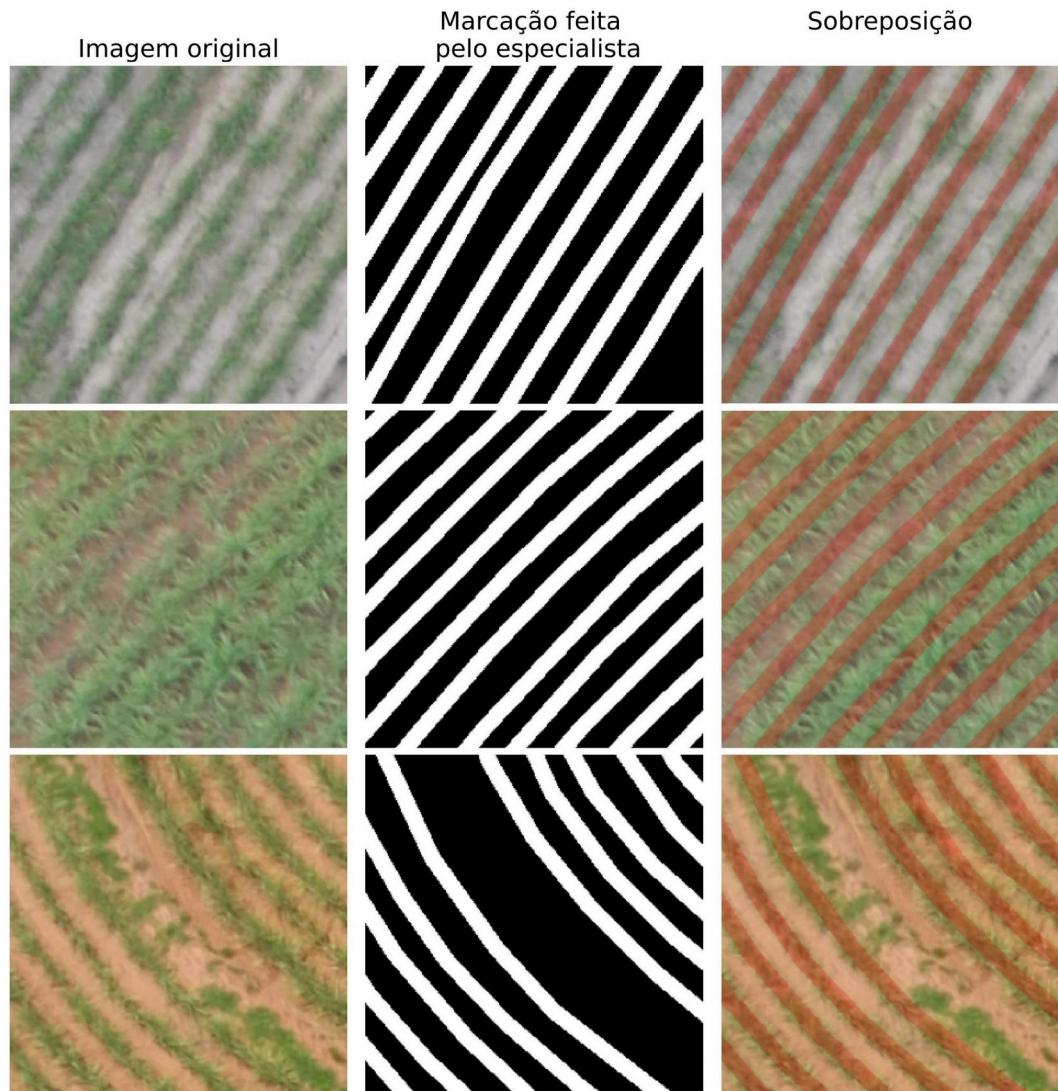


Figura: Mosaicos e seus respectivos tamanhos:

(a) 11180×8449 ; (b) 16677×24181 ; (c) 17497×10771 ; (d) 19833×30255

Figura: Exemplos de marcação nos *datasets*

- **Linha sólida** onde fica a linha de plantio
- Variados estágios de crescimento da cultura e de cores de solo



Metodologia

- Cada mosaico foi recortado em pedaços de **$256 \times 256 \times 3$** pixels **sem sobreposição**
- Após o corte, foi descartado amostras com menos de **80%** de informação útil (i.e., pixels com **valores diferentes de zero**).
- Após o descarte, os *datasets* A, B, C e D ficaram com total de 678, 3.291, 1.552 e 2.162 imagens, respectivamente.

Avaliação dos Resultados

Coeficiente de Dice (CD):

- A e B são imagens binárias
 - $0 \leq CD(A, B) \leq 1$

$$CD(A, B) = 2 \frac{|A \cap B|}{|A + B|}$$

Coeficiente de Jaccard (CJ):

- Função de custo nas CNNs
- *Intersection over Union (IoU)*
 - $0 \leq CJ(A, B) \leq 1$

$$CJ(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Experimentos e Resultados

EC1: CNNs para segmentação com *transfer learning* e *fine-tuning*

Três modelos: U-Net, LinkNet e PSPNet

- Biblioteca ***Segmentation Models***¹
- *Backbone*: **VGG16** pré-treinada com o ImageNet 2012
- Imagens de entradas devem ter tamanho específico
 - U-Net e LinkNet: 256x256, PSPNet: 240x240

Treinamento

- 50 épocas, otimizador Adam com 0,001 de taxa de aprendizado e tamanho de lote de 2

¹Disponível em: https://github.com/qubvel/segmentation_models. Acesso em: 14 de agosto de 2023.

EC1: CNNs para segmentação com *transfer learning* e *fine-tuning*

Treinamento

- **Métodos simples de aumento de dados:** rotação (até $\pm 180^\circ$), translação (até $\pm 20\text{px}$), dimensionamento (até $\pm 7\%$) e cisalhamento
- Validação cruzada *k-fold*, com $k = 10$
 - 90% dos dados para treinamento e 10% para teste
- Após o treinamento é realizada a **predição** de cada *dataset* e depois é o calculo do CD e o seu valor médio

EC1: CNNs para segmentação com *transfer learning* e *fine-tuning*

- Tabela: Média do CD obtido para cada rede durante o treinamento e teste, com *k-fold*

- **Treinamento x Teste**

- **Grande oscilações nos resultados, e.g., CxA e CxD**

- Melhores resultados: **U-Net**

	Rede	Treinamento		Teste	
		A	B	C	D
U-Net	A	0,9080	0,8851	0,8494	0,8150
	B	0,8181	0,9233	0,8922	0,7440
	C	0,6322	0,8847	0,9044	0,5288
	D	0,8914	0,8938	0,8634	0,8672
LinkNet	A	0,8907	0,8585	0,8311	0,7905
	B	0,7969	0,9030	0,8688	0,7284
	C	0,7133	0,8665	0,8835	0,6195
	D	0,8743	0,8653	0,8313	0,8358
PSPNet	A	0,8707	0,7982	0,7393	0,7596
	B	0,7622	0,8861	0,7737	0,7599
	C	0,5999	0,8420	0,8661	0,6046
	D	0,8587	0,6646	0,5487	0,8410

EC1: CNNs para segmentação com *transfer learning* e *fine-tuning*

- Tabela: Média do CD obtido ao treinar cada rede nos *datasets* E(N) e testar nos outros *datasets*

- Novo *dataset* E(N)

- Resultado mais estáveis

- Tamanho do *dataset* E(N) com pouca influência no resultado

Rede	Treinamento	Teste			
		A	B	C	D
U-Net	E(200)	0,9049	0,9099	0,8916	0,8422
	E(300)	0,9043	0,9104	0,8955	0,8482
	E(400)	0,9069	0,9137	0,8968	0,8495
	E(500)	0,9096	0,9155	0,8993	0,8547
LinkNet	E(200)	0,8821	0,8905	0,8697	0,8090
	E(300)	0,8835	0,8920	0,8740	0,8206
	E(400)	0,8823	0,8936	0,8742	0,8196
	E(500)	0,8849	0,8952	0,8762	0,8238
PSPNet	E(200)	0,8653	0,8679	0,8560	0,8158
	E(300)	0,8648	0,8713	0,8523	0,8185
	E(400)	0,8751	0,8779	0,8605	0,8263
	E(500)	0,8748	0,8795	0,8609	0,8304

EC1.1: Influência do *transfer learning* e *fine-tuning* na segmentação

- Tabela: Média do CD obtido utilizando *transfer-learning*, mas sem *fine-tuning*
- Mesmo hiperparâmetros EC1, mas sem *k-fold*
- Mais parâmetros livres para treinamento
- Melhoria de cerca de 3% no CD
- Maior tempo para treinamento
- Similar para E(N)

Rede	Treinamento	Teste			
		A	B	C	D
U-Net	A	0,9196	0,9101	0,8946	0,8389
	B	0,8848	0,9367	0,9102	0,8587
	C	0,8875	0,9288	0,9221	0,8722
	D	0,8894	0,9106	0,9087	0,8953
LinkNet	A	0,9183	0,9056	0,8890	0,8395
	B	0,9056	0,9385	0,9144	0,8686
	C	0,8610	0,9167	0,9150	0,8259
	D	0,8998	0,9140	0,9071	0,8922
PSPNet	A	0,9083	0,8991	0,8843	0,8409
	B	0,5864	0,6123	0,5936	0,5996
	C	0,8815	0,9127	0,9093	0,8605
	D	0,8993	0,8935	0,8849	0,8509

EC1.1: Influência do *transfer learning* e *fine-tuning* na segmentação

- Tabela: Média do CD obtido **sem utilizar *transfer-learning***

- Resultado similares ao utilizar *transfer learning*, mas sem *fine-tuning*
- *Transfer learning* foi útil para **reduzir o tempo** de treinamento das redes
- **PSPNet teve grande piora** nos resultados, mesmo com os *dataset* E(N)

	Rede	Treinamento	Teste			
			A	B	C	D
U-Net	U-Net	A	0,9186	0,9042	0,8921	0,8379
		B	0,9151	0,9380	0,9140	0,8675
		C	0,8765	0,9066	0,9150	0,8539
		D	0,8908	0,9114	0,9059	0,8847
LinkNet	LinkNet	A	0,9217	0,9146	0,8896	0,8441
		B	0,9104	0,9367	0,9109	0,8605
		C	0,8893	0,9206	0,9170	0,8457
		D	0,8997	0,9111	0,9029	0,8759
PSPNet	PSPNet	A	0,5864	0,6123	0,5936	0,5996
		B	0,5864	0,6123	0,5936	0,5996
		C	0,5864	0,6123	0,5936	0,5996
		D	0,5864	0,6123	0,5936	0,5996

EC2: U-Net e o número de blocos e filtros convolucionais

- Análise da arquitetura da rede
- Código escrito do zero
- Sem utilizar k -fold
- 80% para treinamento e 20% para teste
- 50 épocas, otimizador Adam com 0,001 de taxa de aprendizado e tamanho de lote de 8

EC2: U-Net e o número de blocos e filtros convolucionais

- Tabela: Configurações da U-Net utilizadas nos experimentos

Configuração	Quantidade de blocos e filtros	Total de parâmetros	Porcentagem
01	[16, 32, 64, 128, 256]	3.331.697	100,00%
02	[16, 32, 64, 128]	823.921	24,72%
03	[16, 32, 64]	196.721	5,90%
04	[16, 32]	39.793	1,19%
05	[16]	2.785	0,08%
06	[16, 16]	14.369	0,43%
07	[16, 16, 16]	25.953	0,77%
08	[16, 16, 16, 16]	37.537	1,12%
09	[16, 16, 16, 16, 16]	49.121	1,47%
10	[32]	10.177	0,30%
11	[64]	38.785	1,16%
12	[128]	151.297	4,54%

EC2: U-Net e o número de blocos e filtros convolucionais

Configuração 01: [16, 32, 64, 128, 256]				Configuração 02: [16, 32, 64, 128]				Configuração 03: [16, 32, 64]				Configuração 04: [16, 32]							
	A	B	C	D	A	B	C	D	A	B	C	D	A	B	C	D			
A	0,96	0,68	0,84	0,73	A	0,94	0,69	0,82	0,70	A	0,92	0,69	0,81	0,69	A	0,86	0,60	0,74	0,65
B	0,90	0,97	0,90	0,84	B	0,88	0,95	0,89	0,80	B	0,64	0,93	0,85	0,65	B	0,54	0,89	0,75	0,57
C	0,90	0,91	0,96	0,86	C	0,87	0,91	0,94	0,79	C	0,61	0,88	0,90	0,49	C	0,65	0,79	0,85	0,57
D	0,87	0,91	0,89	0,94	D	0,84	0,87	0,85	0,92	D	0,83	0,86	0,81	0,88	D	0,78	0,79	0,74	0,81
Configuração 05: [16]				Configuração 06: [16, 16]				Configuração 07: [16, 16, 16]				Configuração 08: [16, 16, 16, 16]							
	A	B	C	D	A	B	C	D	A	B	C	D	A	B	C	D			
A	0,69	0,14	0,42	0,59	A	0,84	0,53	0,74	0,63	A	0,90	0,67	0,79	0,69	A	0,92	0,63	0,82	0,71
B	0,27	0,69	0,61	0,24	B	0,55	0,88	0,73	0,56	B	0,69	0,92	0,86	0,67	B	0,84	0,94	0,89	0,76
C	0,50	0,60	0,65	0,41	C	0,69	0,82	0,85	0,61	C	0,70	0,87	0,88	0,52	C	0,84	0,89	0,92	0,70
D	0,64	0,30	0,49	0,63	D	0,77	0,76	0,72	0,80	D	0,77	0,81	0,80	0,85	D	0,85	0,89	0,85	0,89
Configuração 09: [16, 16, 16, 16, 16]				Configuração 10: [32]				Configuração 11: [64]				Configuração 12: [128]							
	A	B	C	D	A	B	C	D	A	B	C	D	A	B	C	D			
A	0,93	0,67	0,83	0,71	A	0,75	0,25	0,48	0,62	A	0,76	0,38	0,54	0,63	A	0,74	0,29	0,47	0,59
B	0,91	0,94	0,91	0,83	B	0,29	0,71	0,61	0,28	B	0,36	0,75	0,63	0,37	B	0,26	0,71	0,62	0,25
C	0,91	0,91	0,92	0,80	C	0,51	0,61	0,67	0,43	C	0,54	0,63	0,69	0,45	C	0,49	0,60	0,68	0,40
D	0,84	0,90	0,86	0,90	D	0,65	0,34	0,50	0,64	D	0,62	0,24	0,50	0,63	D	0,69	0,39	0,57	0,68

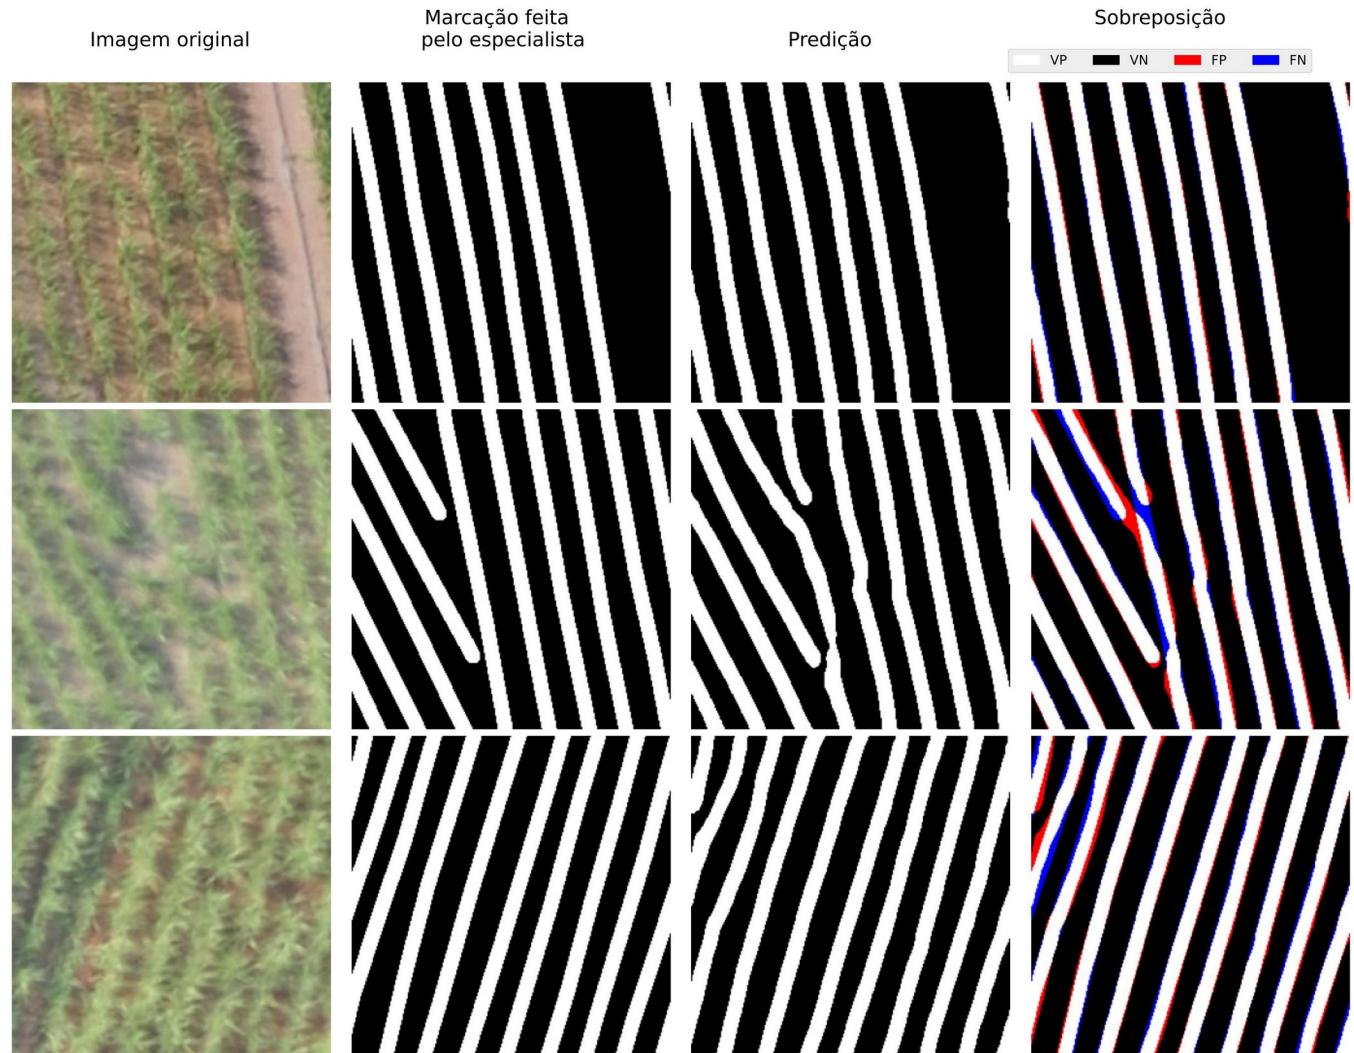
EC2: U-Net e o número de blocos e filtros convolucionais

- Tabela: Configuração 01 e 09 realizadas no *dataset* E(500)

Configuração 01:					Configuração 09:				
	A	B	C	D		A	B	C	D
E	0,96	0,94	0,94	0,87	E	0,94	0,93	0,92	0,86

- Resultados mais estáveis ao utilizar o *dataset* E(N)
- Resultados bem próximos entre as Configurações, a **09 tem apenas 1,47%** de parâmetros da 01

Figura: Exemplos de segmentação da U-Net com a **Configuração 09**



EC3: Índices de Vegetação na U-Net

- Tabela: Resultados de CD médio da U-Net na Configuração 01 ([16, 32, 64, 128, 256])
- Banda RGB e um IV

IV	<i>Dataset</i>			
	A	B	C	D
00_none	0,9420	0,9332	0,9211	0,8872
01_VARI	0,9552	0,9361	0,9294	0,8923
02_ExG	0,9538	0,9408	0,9299	0,8964
03_ExR	0,9483	0,9388	0,9282	0,8954
04_ExB	0,9521	0,9406	0,9299	0,8965
05_EXGR	0,9507	0,9380	0,9305	0,8913
06_GRVI	0,9568	0,9389	0,9329	0,8963
07_MGRVI	0,9541	0,9335	0,9286	0,8897
08_GLI	0,9456	0,9351	0,9244	0,8848
09_RGBVI	0,9414	0,9355	0,9211	0,8948
10_IKAW	0,9469	0,9345	0,9250	0,8923

EC3: Índices de Vegetação na U-Net

- Tabela: Resultados de CD médio da U-Net na Configuração 09 ([16, 16, 16, 16])

- Banda RGB e mais de um IV

IVs	<i>Dataset</i>			
	A	B	C	D
00_none	0,9289	0,9266	0,9145	0,8754
01 até 05	0,9302	0,9253	0,9136	0,8751
06 até 10	0,9321	0,9308	0,9175	0,8818
01 até 10	0,9305	0,9305	0,9158	0,8779

EC3: Índices de Vegetação na U-Net

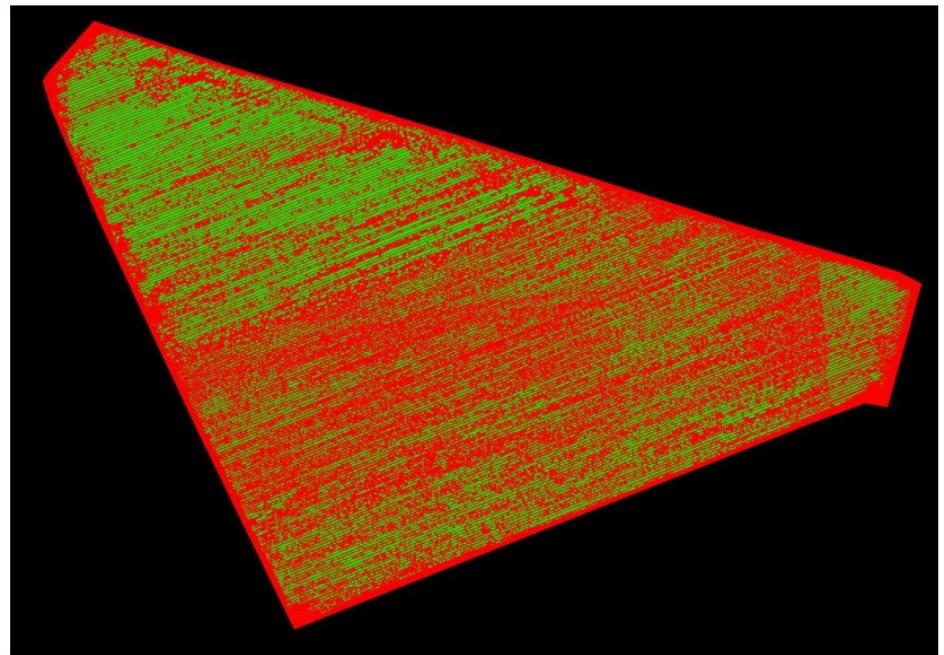
- Tabela: CD médio para a Configuração 09 ([16, 16, 16, 16, 16]) com apenas IVs
- Resultado **similar** ao utilizar apenas as bandas **RGB**
- Pode ser útil em locais com **limitação de banda** ou **poder computacional**

IV	<i>Dataset</i>			
	A	B	C	D
01_VARI	0,9225	0,9243	0,9101	0,8735
02_ExG	0,9247	0,9242	0,9126	0,8731
03_ExR	0,9263	0,9240	0,9112	0,8771
04_ExB	0,9108	0,8774	0,8984	0,8287
05_EXGR	0,9270	0,9234	0,9120	0,8723
06_GRVI	0,9253	0,9253	0,9111	0,8751
07_MGRVI	0,9248	0,9255	0,9135	0,8761
08_GLI	0,9257	0,9246	0,9139	0,8765
09_RGBVI	0,9240	0,9222	0,9127	0,8710
10_IKAW	0,8560	0,8973	0,8496	0,8309

EC4: *dataset L*



(a)

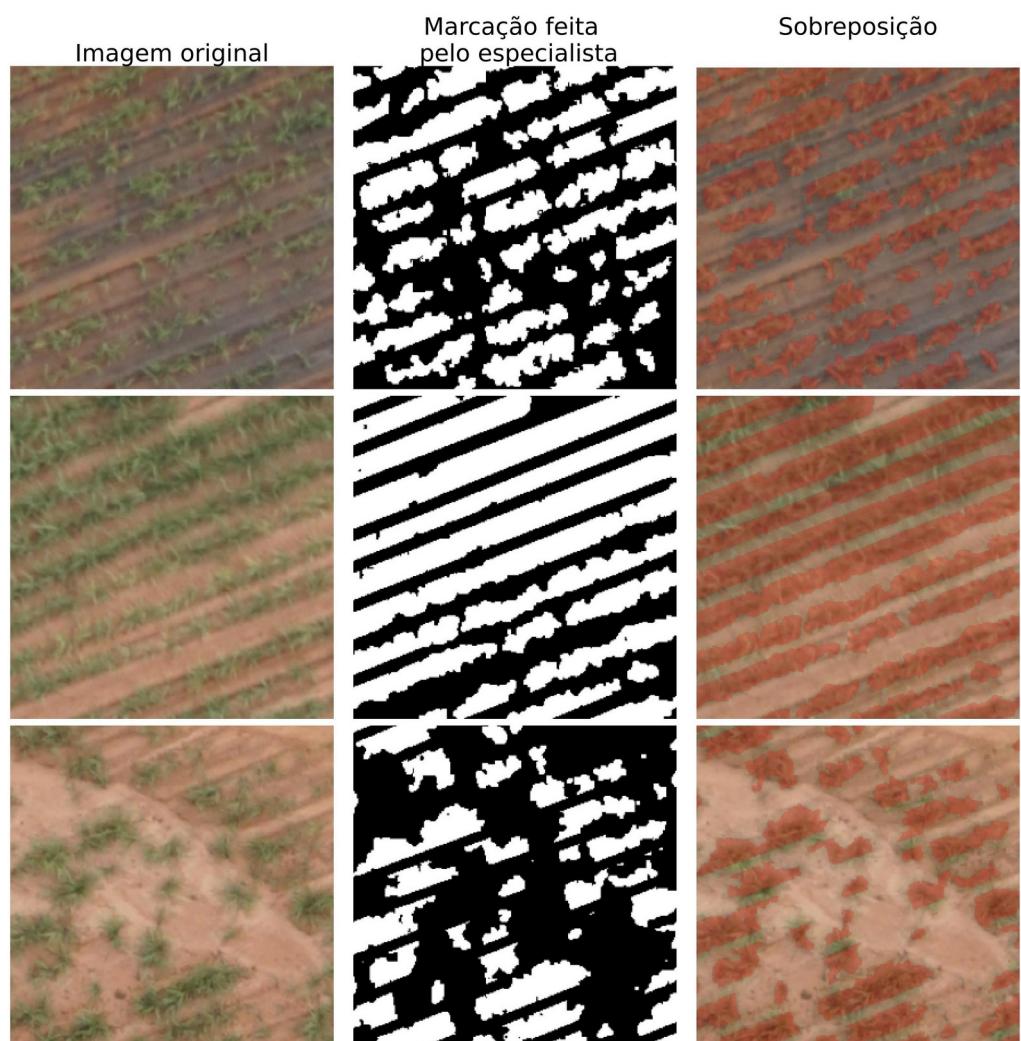


(b)

Figura: Mosaico Pereira Júnior e Wangenheim (2019) - LAPIX: (a) mosaico de tamanho 6595×9391 ; (b) marcação do especialista

EC4: *dataset L*

- Figura: Exemplos de marcação no *dataset*, aqui renomeado de L
- Marcação diferente dos *datasets* anteriores
 - Apenas nos pixel que representam a cultura



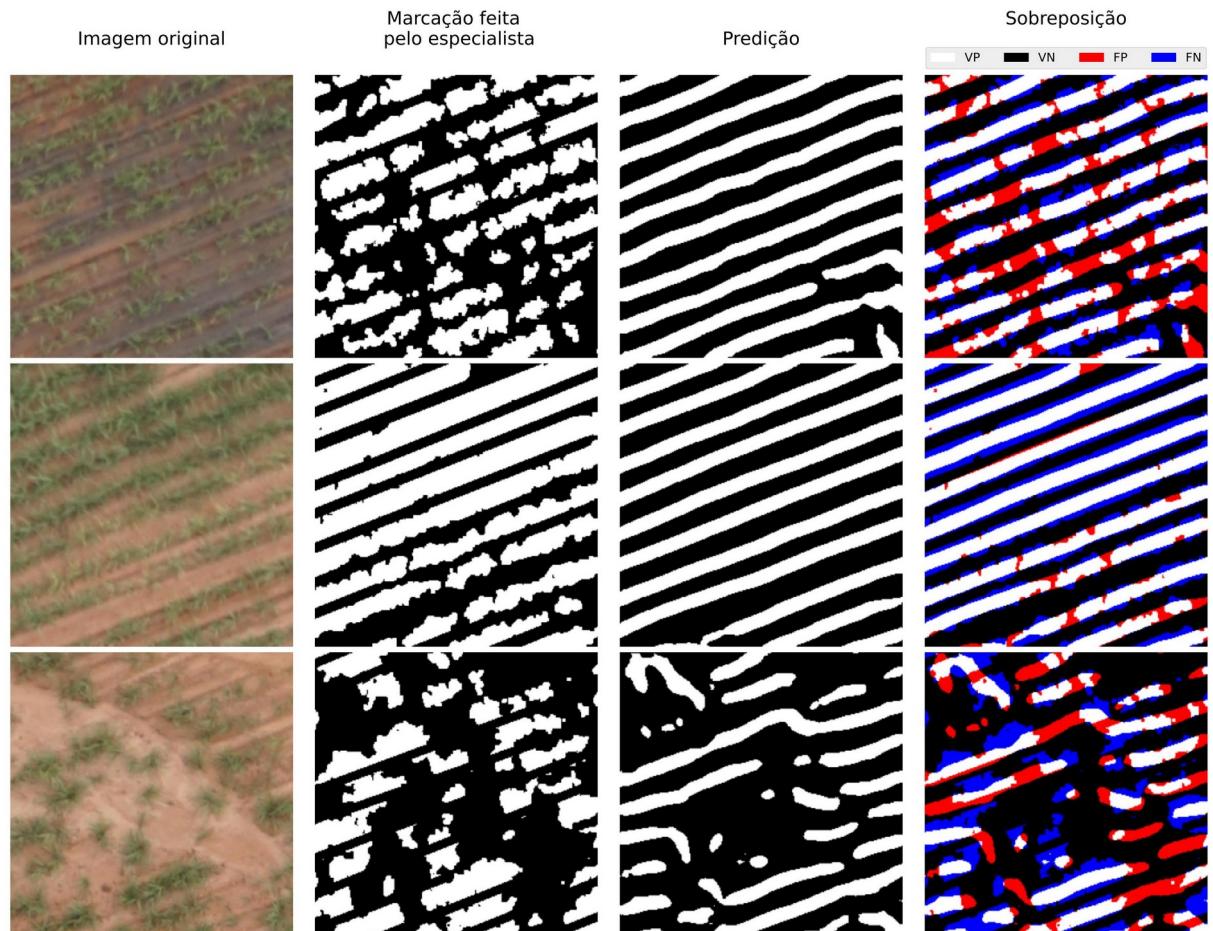
EC4: *dataset* L

- Alteração dos pixels da cultura de verde para branco e os pixel do solo de vermelho para preto
- Após o recorte (256×256) e descarte (menos 80% de informação útil) o *dataset* L ficou com **406 imagens**
- Tabela: CD médio dos resultados dos modelos treinados na **U-Net** com ***dataset* E(500)**

	A	B	C	D	L
Configuração 01	0,9420	0,9332	0,9211	0,8872	0,6760
Configuração 09	0,9289	0,9266	0,9145	0,8754	0,6682

EC4: *dataset L*

- Figura: Exemplos de predição do *dataset L* pelo modelo treinado com o *dataset E(500)* na U-Net com a **Configuração 09**
- pode ser útil para **identificar e conectar as linhas de plantio**
- Ou ser utilizado com **entrada para outro** método



EC4: *dataset L*

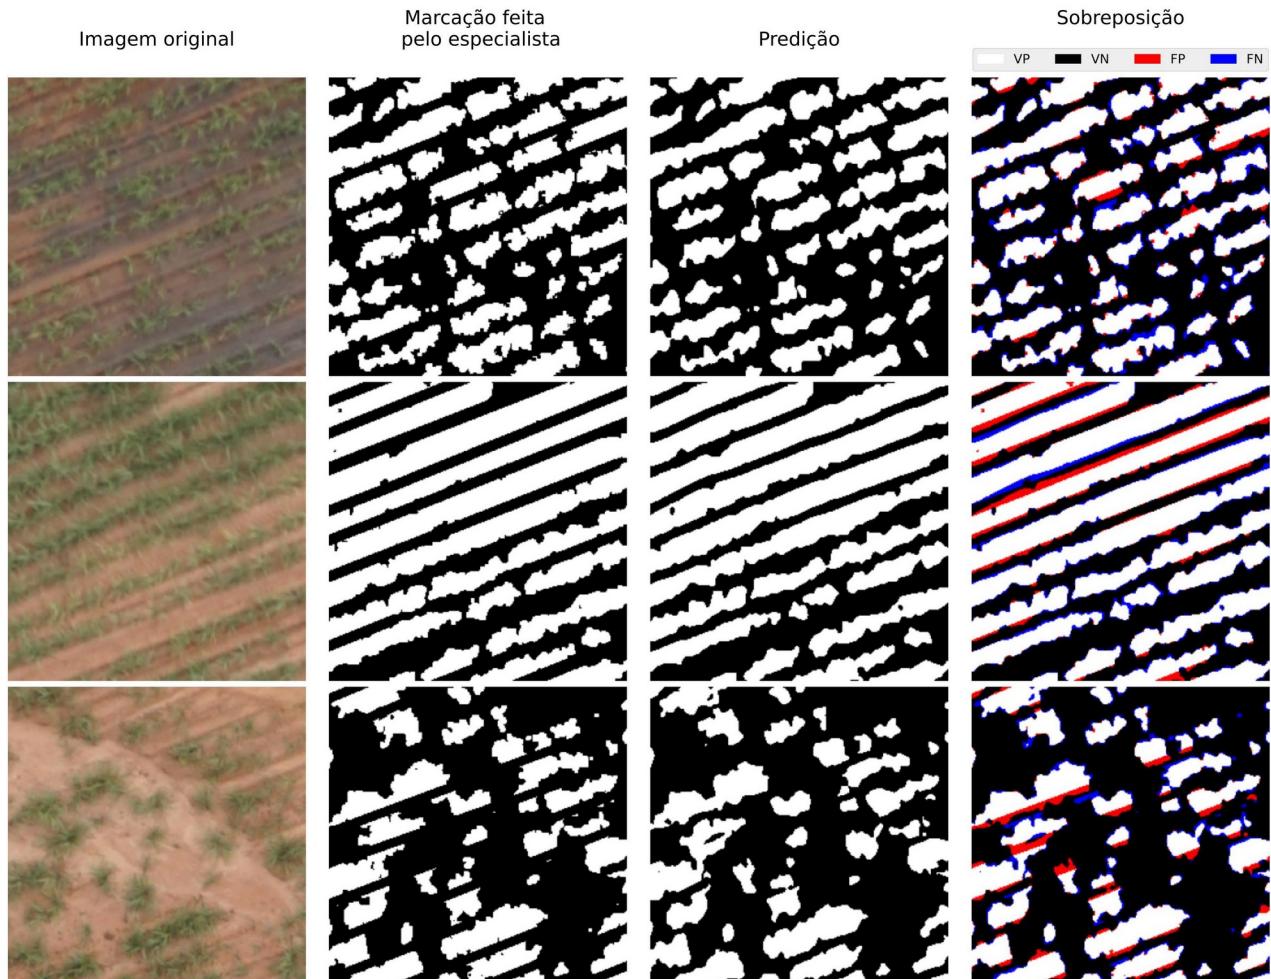
- Tabela: CD médio dos resultados dos modelos treinados na **U-Net com dataset L**

	A	B	C	D	L
Configuração 01	0,5530	0,6375	0,5836	0,5730	0,9179
Configuração 09	0,5196	0,6177	0,5608	0,5621	0,9044

- **Treinamento e teste no dataset L** obteve resultado equivalente aos anteriores, em torno de 0,90 de CD
- A **configuração 09** foi capaz de apreender as características do *dataset L* (**406** imagens)

EC4: *dataset L*

- Figura: Exemplos de predição do *dataset L* pelo modelo treinado com o *dataset L* na U-Net com a **Configuração 09**
- Busca segmentar **apenas os pixels que julga ser da cultura**



EC5: Operações Morfológicas

- Tabela: Resultado CD médio após aplicar as **operações morfológicas** na segmentação da U-Net na Configuração 01 treinada com o dataset E(500)

	IV	A	B	C	D
Configuração 01	00_none	0,9420	0,9332	0,9211	0,8872

- Sem melhoria no resultado
- Independente do elemento estruturante

Operação	Elemento	A	B	C	D
Erosão	Cruz	0,8969	0,8975	0,8768	0,8535
	Todos_1	0,8798	0,8625	0,8571	0,8320
Dilatação	Cruz	0,9193	0,9159	0,9010	0,8774
	Todos_1	0,9099	0,8951	0,8902	0,8668
Abertura	Cruz	0,9320	0,9286	0,9146	0,8846
	Todos_1	0,9419	0,9331	0,9210	0,8870
Fechamento	Cruz	0,9320	0,9286	0,9146	0,8846
	Todos_1	0,9419	0,9331	0,9211	0,8872

Conclusão

Conclusão

- As CNNs conseguiram segmentar bem as imagens, com **CD de 0,90** ou mais. A U-Net obteve bons resultados, principalmente a **Configuração 01 e 09**
- O *dataset* utilizado no **treinamento** e modo de **marcação** influenciam bastante no resultado
- As técnicas **simples** de aumento de dados utilizadas **não foram efetivas**
- O uso de apenas um IV, como **ExG**, poder ser uma alternativa para locais com limitações (e.g., de poder computacional)

Principais Contribuições

- Demonstrar a **capacidade das CNNs para segmentar imagens** capturadas por VANTs de plantações de cana-de-açúcar
- **Análise aprofundada da U-Net**, com recomendações de configurações para determinados cenários
- Avaliação da possibilidade de **utilização dos IVs no treinamento** da U-Net, com **recomendações de utilização**
- Repositório:
https://github.com/ryuuzaki42/Deteccao_de_linhas_de_plantio_em_plantacoes_de_cana-de-acucar_utilizando_deep_learning

Limitações e Trabalhos Futuros

Avaliação de 3 CNNs

- Outras podem **obter resultados melhores**

Avaliação de apenas bandas RGB

- **Infravermelho** e outras bandas podem ter **influência no treinamento**
- Avaliar os IVs (e outros com outras bandas) nas **outras CNNs**

Avaliar a abordagem proposta, principalmente a U-Net com configuração 01 e 09, em **outras culturas**

Contribuições em Produção Bibliográfica

- RIBEIRO, J. B., SILVA, R. R. d., DIAS JÚNIOR, J. D., ESCARPINATI, M. C., BACKES, A. R.. Automated detection of sugarcane crop lines from UAV images using deep learning. **Information Processing in Agriculture**, 2023. ISSN 2214-3173. Disponível em:
<https://doi.org/10.1016/j.inpa.2023.04.001>

Submetido e em fase de análise:

- RIBEIRO, J. B., BACKES, A. R.. Adjusting convolution blocks of U-Net to improve sugarcane crop line segmentation. **Submetido ao Soft Computing**

O estudo de conceitos do projeto me permitiu contribuir com o artigo:

- DIAS JÚNIOR, J. D.; RIBEIRO, J. B.; BACKES, A. R.. Assessing the impact of JPEG compression on the semantic segmentation of agricultural images. **Signal, Image and Video Processing**, 2023. ISSN 1863-1711. Disponível em: <https://doi.org/10.1007/s11760-023-02697-7>

Agradecimentos



**Universidade
Federal de
Uberlândia**



A banca, pelo interesse, disponibilidade,
futuras contribuições e críticas



**Faculdade de
Computação**

Agências de Fomento



Orientador: Prof. Dr. André
Coorientador: Prof. Dr. Mauricio

Obrigado pela atenção! :-)

João Batista
joao.b@ufu.br

